

Learning Transferable Visual Models From Natural Language Supervision


Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh,
Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Aspell,
Pamela Mishkin, Jack Clark, Gretchen Krueger, Ilya Sutskever

임서진

연구 배경 / 기존 컴퓨터 비전 모델의 한계

기존 컴퓨터 비전 모델: 미리 정해진 고정된 물체 범주들을 예측 하도록 학습됨.

-> 다른 시각적 개념을 지정하려면 추가적 라벨링 필요




CLIP(Contrastive Language-Image Pre-training)

사전학습 후, 자연어를 사용하여 학습된 시각 개념을 가리키거나 새로운 개념을 설명할 수 있으며, 이를 통해 모델을 하위 과제에 zero-shot transfer 할 수 있다.

ImageNet 128만 장을 직접 학습하지 않고도, zero-shot으로 ResNet-50과 유사한 정확도를 보였다.

(1) Contrastive pre-training




CLIP

원시 텍스트로부터 직접 학습하는 사전학습 방법으로 특정 과제에 종속되지 않는 모델 구조가 하위 데이터셋에 zero-shot transfer 가능.

ex) GPT-3: 데이터셋별 학습 데이터 거의 사용하지 않음.

컴퓨터 비전에서 이런 방식 적용 -> CLIP : 사용 가능한 최고 수준의 ImageNet 모델보다 더 높은 성능 보임.

OCR, 지리적 위치 추정, 행동 인식 등 다양한 과제를 수행하는 능력을 학습




표준 이미지 모델: 어떤 라벨을 예측하기 위해 이미지 특징 추출기와 선형 분류기를 함께 학습.


CLIP: 이미지-텍스트 학습 예시들로 이루어진 배치 안에서 올바른 이미지와 텍스트의 짝을 예측하도록 이미지 인코더와 텍스트 인코더를 함께 학습.

테스트할 때는 학습된 text Encoder가 대상 데이터셋 클래스의 이름이나 설명을 임베딩하여, zero-shot linear classifier만들어냄.

(1) Contrastive pre-training



(2) Create dataset classifier from label text



2. Approach

이미지 + 자연어 텍스트로 학습

처음: 캡션을 직접 맞추는 방식 -> contrastive learning(대조 학습 방식:문장을 직접 만들지 않고 이미지와 가장 잘 맞는 텍스트가 무엇인지 고름)



Image Encoder(ResNet 또는 ViT), Text Encoder(Transformer)에 image와 text를 숫자 벡터로 바꿔서

- 맞는 쌍이면 유사도가 높아져 가까워짐
- 틀리면 유사도가 낮아져 멀어짐

반복하면 CLIP은 이미지와 언어를 같은 의미 공간에 배치 가능.

3. Experiments

- CLIP은 ImageNet 학습 데이터 128만 장을 직접 사용하지 않고도, zero-shot 방식으로 ResNet-50 수준의 성능을 달성.
- 단순 클래스명보다 "a photo of a {label}"처럼 문맥이 있는 prompt를 사용하면 zero-shot 성능이 향상된다.
- 다양한 이미지-텍스트 데이터로 학습한 CLIP은 자연스러운 분포 변화에서 더 높은 robustness를 보임.




4. Comparison to Human Performance

CLIP은 zero-shot 성능은 매우 강하지만,

인간처럼 적은 예시를 보고 빠르게 배우는 능력은 아직 부족함.

-> CLIP의 발전을 위해서는 인간처럼 기존 지식을 few-shot 학습에 잘 활용하는 방법 필요.



5. Limitation

최고 성능 모델 수준은 아님.

세밀한 분류, 물체 개수 세기, 새로운 과제에는 약함.

또한 학습 데이터와 크게 다른 분포의 데이터에는 일반화가 잘 되지 않고, 주어진 후보 중에서만 답을 고를 수 있다는 제한있음.

CLIP: 매우 큰 인터넷 이미지-텍스트 데이터를 활용해 성능을 얻는 방식

➔앞으로는 CLIP의 zero-shot 장점을 유지하면서도 데이터 효율성, few-shot 학습 능력, 편향 문제를 개선하는 연구가 필요.

끝! 감사합니다.